

Raport 4

Dagmara Skowron

2026-05-24

Cel sprawozdania

Celem sprawozdania jest porównanie kilku metod estymacji współczynników w modelu liniowym w przypadku dużej liczby zmiennych. Analizowane są: metoda najmniejszych kwadratów, regresja grzbietowa, LASSO, adaptacyjne LASSO oraz procedury z użyciem knockoffów.

Porównanie wykonano pod względem błędu estymacji, błędu średniokwadratowego, liczby fałszywych odkryć oraz mocy wykrywania zmiennych istotnych.

Opis eksperymentu

Rozważany jest model liniowy

$$Y = X\beta + \varepsilon,$$

gdzie X jest macierzą planu, β jest wektorem współczynników regresji, a ε jest wektorem błędów losowych.

W eksperymencie przyjęto

$$n = p = 500,$$

czyli liczba obserwacji jest równa liczbie zmiennych. Błędy losowe pochodzą z rozkładu normalnego

$$\varepsilon \sim N(0, I).$$

Wektor współczynników β ma tylko k pierwszych elementów różnych od zera. Przyjęto dwa warianty wartości tych współczynników:

$$\beta_1 = \dots = \beta_k = 4,$$

oraz

$$\beta_1 = \dots = \beta_k = \sqrt{\frac{80}{k}}.$$

Pozostałe współczynniki są równe zero. Obliczenia wykonano dla

$$k \in \{5, 20, 100\}.$$

Założenia

Dane wygenerowano z modelu liniowego $Y = X\beta + \varepsilon$, gdzie błędy mają rozkład normalny $N(0, I)$. Przyjęto $n = p = 500$. W modelu tylko pierwsze k współczynników wektora β jest różnych od zera, dla $k \in \{5, 20, 100\}$. Analizowano dwa typy macierzy planu: ortonormalną oraz losową o elementach z rozkładu normalnego.

Zadanie 1

W tej części analizowana jest ortonormalna macierz planu, czyli taka, dla której spełniony jest warunek

$$X'X = I.$$

1a. Obciążenie, wariancja i MSE dla regresji grzbietowej

Dla regresji grzbietowej przy $X'X = I$ estymator ma postać

$$\hat{\beta}_i^{ridge} = \frac{X'_i Y}{1 + \gamma}.$$

Ponieważ $X'_i Y = \beta_i + \eta_i$, gdzie $\eta_i \sim N(0, 1)$, można wyznaczyć obciążenie, wariancję i MSE teoretycznie.

Obciążenie wynosi

$$Bias(\hat{\beta}_i) = -\frac{\gamma}{1 + \gamma} \beta_i.$$

Wariancja wynosi

$$Var(\hat{\beta}_i) = \frac{1}{(1 + \gamma)^2}.$$

MSE pojedynczego współczynnika wynosi

$$MSE(\hat{\beta}_i) = \frac{\gamma^2 \beta_i^2 + 1}{(1 + \gamma)^2}.$$

W tabeli przedstawiono wartości obciążenia, wariancji i MSE dla kilku przykładowych wartości współczynnika β_i .

Table 1: Obciążenie, wariancja i MSE dla ridge przy gamma = 1

Typ	Beta	Gamma	Obciążenie	Wariancja	MSE
zmienna nieistotna	0.00	1	0.00	0.25	0.25
zmienna istotna	4.00	1	-2.00	0.25	4.25
zmienna istotna	2.00	1	-1.00	0.25	1.25
zmienna istotna	0.89	1	-0.45	0.25	0.45

Powyższa tabela pokazuje, że dla zmiennej nieistotnej, czyli gdy $\beta_i = 0$, obciążenie wynosi 0, a MSE jest równe samej wariancji. Dla zmiennych istotnych regresja grzbietowa zaniża współczynniki, dlatego obciążenie jest ujemne. Im większa wartość β_i , tym większe obciążenie i większy MSE. Wariancja jest taka sama dla wszystkich współczynników, ponieważ zależy tylko od parametru γ .

1b. Optymalne parametry γ i λ

W tym punkcie wyznaczono parametry dające najmniejszy błąd MSE.

Dla regresji grzbietowej całkowity błąd MSE wynosi

$$MSE(\gamma) = \frac{\gamma^2 \|\beta\|^2 + p}{(1 + \gamma)^2}.$$

Stąd optymalna wartość parametru γ jest równa

$$\gamma^* = \frac{p}{\|\beta\|^2}.$$

Minimalny MSE dla regresji grzbietowej wynosi

$$MSE_{ridge}^{min} = \frac{p \|\beta\|^2}{p + \|\beta\|^2}.$$

Poniższa tabela pokazuje optymalne parametry ridge i LASSO dla każdego wariantu β i wartości k .

Table 2: Optymalne parametry ridge i LASSO

k	Wariant	$\ \beta\ ^2$	Gamma	MSE ridge	Lambda	MSE LASSO
5	$\beta = 4$	80	6.25	68.97	1.90	30.18
20	$\beta = 4$	320	1.56	195.12	1.45	86.60
100	$\beta = 4$	1600	0.31	380.95	0.90	256.10
5	$\beta = \sqrt{80/k}$	80	6.25	68.97	1.95	30.17
20	$\beta = \sqrt{80/k}$	80	6.25	68.97	1.85	62.73
100	$\beta = \sqrt{80/k}$	80	6.25	68.97	2.20	78.23

Tabela pokazuje, że dla wariantu $\beta = 4$ optymalna wartość γ maleje wraz ze wzrostem k , ponieważ rośnie wartość $\|\beta\|^2$. W wariancie $\beta = \sqrt{80/k}$ wartość $\|\beta\|^2$ jest stała, dlatego wyniki ridge są takie same dla wszystkich k . LASSO najlepiej wypada przy małej liczbie zmiennych istotnych.

1c. Porównanie MSE dla MNK, ridge i LASSO

W tym punkcie porównano błąd MSE metody najmniejszych kwadratów z najlepszymi wynikami uzyskanymi dla ridge i LASSO.

Dla metody najmniejszych kwadratów przy $X'X = I$ mamy

$$\hat{\beta}^{MNK} = X'Y.$$

Zatem wariancja każdego współczynnika wynosi 1, a całkowity błąd MSE wynosi

$$MSE_{MNK} = p.$$

W tabeli zestawiono MSE metody MNK z najmniejszymi wartościami MSE uzyskanymi dla ridge i LASSO.

Table 3: Porównanie MSE dla MNK, ridge i LASSO

k	Wariant	MSE MNK	MSE ridge	MSE LASSO	Gamma	Lambda
5	$\beta = 4$	500	68.97	30.18	6.25	1.90
20	$\beta = 4$	500	195.12	86.60	1.56	1.45
100	$\beta = 4$	500	380.95	256.10	0.31	0.90
5	$\beta = \sqrt{80/k}$	500	68.97	30.17	6.25	1.95
20	$\beta = \sqrt{80/k}$	500	68.97	62.73	6.25	1.85
100	$\beta = \sqrt{80/k}$	500	68.97	78.23	6.25	2.20

W każdym przypadku metoda MNK ma największy MSE równy 500. Regresja grzbietowa i LASSO wyraźnie zmniejszają błąd estymacji. Najmniejsze wartości MSE uzyskuje LASSO, szczególnie dla małych i średnich wartości k . Dla wariantu $\beta = \sqrt{80/k}$ regresja grzbietowa ma stały MSE, ponieważ wartość $\|\beta\|^2$ jest taka sama dla wszystkich wartości k .

1d. Fałszywe odkrycia i moc dla LASSO

W tym punkcie wyznaczono teoretyczną średnią liczbę fałszywych odkryć oraz moc LASSO dla optymalnej wartości parametru λ .

W LASSO zmienna zostaje wybrana wtedy, gdy

$$|X_i'Y| > \lambda.$$

Dla zmiennej nieistotnej mamy $\beta_i = 0$, więc

$$X_i'Y \sim N(0, 1).$$

Średnia liczba fałszywych odkryć wynosi

$$E(V) = (p - k)2(1 - \Phi(\lambda)).$$

Dla zmiennej istotnej, gdzie $\beta_i = b$, moc wynosi

$$\text{Moc} = P(|N(b, 1)| > \lambda).$$

Podsumowanie zadania 1

Poniższa tabela zbiera najważniejsze wyniki z zadania 1. Pokazano w niej MSE dla MNK, optymalne MSE dla ridge i LASSO, dobrane wartości parametrów oraz własności selekcji zmiennych dla LASSO.

Table 4: Podsumowanie wyników dla zadania 1

k	Wariant	MSE MNK	MSE ridge	MSE LASSO	Gamma	Lambda	Fałszywe	Moc
100	$\beta = 4$	500	380.95	256.10	0.31	0.90	147.25	1.00
100	$\beta = \sqrt{80/k}$	500	68.97	78.23	6.25	2.20	11.12	0.10
20	$\beta = 4$	500	195.12	86.60	1.56	1.45	70.59	0.99
20	$\beta = \sqrt{80/k}$	500	68.97	62.73	6.25	1.85	30.87	0.56
5	$\beta = 4$	500	68.97	30.18	6.25	1.90	28.43	0.98
5	$\beta = \sqrt{80/k}$	500	68.97	30.17	6.25	1.95	25.33	0.98

Ridge i LASSO wyraźnie zmniejszają MSE względem MNK. LASSO daje najmniejsze błędy, ale przy większym k może generować więcej fałszywych odkryć. Gdy $\beta = \sqrt{80/k}$, moc LASSO spada dla dużych wartości k , ponieważ pojedyncze współczynniki są wtedy słabsze.

Zadanie 2

W tym zadaniu macierz planu nie jest już ortonormalna. Jej elementy są niezależnymi zmiennymi losowymi z rozkładu normalnego

$$X_{ij} \sim N\left(0, \frac{1}{n}\right).$$

Dla każdego przypadku estymowany jest wektor β za pomocą czterech metod: regresji grzbietowej, LASSO oraz dwóch wersji adaptacyjnego LASSO. Następnie porównywane są błędy estymacji, FDR oraz moc wykrywania zmiennych istotnych.

2a. Estymacja wektora β

W tym punkcie wyznaczono estymatory β czterema metodami. Dla regresji grzbietowej, LASSO oraz pierwszej wersji adaptacyjnego LASSO parametr regularyzacji dobrano za pomocą walidacji krzyżowej.

2b. Porównanie błędu SE

W tym punkcie porównano błąd estymacji

$$SE = \|\hat{\beta} - \beta\|^2.$$

Im mniejsza wartość SE , tym dokładniej dana metoda odtwarza prawdziwy wektor współczynników.

Table 5: Błąd SE i liczba wybranych zmiennych: $\beta = 4$

Metoda	k = 5		k = 20		k = 100	
	SE	Wybrane	SE	Wybrane	SE	Wybrane
Ridge	77.13	500	307.50	500	1529.91	500
LASSO	32.77	30	129.09	54	405.54	209
Ad. LASSO R	64.21	68	125.18	86	406.25	182
Ad. LASSO L	39.07	15	108.50	31	332.68	129

Table 6: Błąd SE i liczba wybranych zmiennych: $\beta = \sqrt{80/k}$

Metoda	k = 5		k = 20		k = 100	
	SE	Wybrane	SE	Wybrane	SE	Wybrane
Ridge	76.69	500	79.95	500	76.87	500
LASSO	26.18	36	65.50	17	80.05	20
Ad. LASSO R	42.38	51	70.57	49	142.37	93
Ad. LASSO L	115.08	35	96.20	15	102.41	11

Ridge wybiera wszystkie zmienne, ponieważ nie wykonuje selekcji. LASSO i adaptacyjne LASSO wybierają mniej zmiennych i zwykle dają mniejszy SE. Dla większego k błąd estymacji rośnie, szczególnie w wariancie $\beta = 4$.

2c. Knockoffy, FDR i moc

W tym punkcie zastosowano procedurę knockoff. Jej celem jest wybór zmiennych istotnych przy kontroli FDR na poziomie 0.2.

Porównano FDR i moc dla zwykłego LASSO, dwóch wersji adaptacyjnego LASSO oraz knockoffów opartych na LASSO i regresji grzbietowej.

Table 7: FDR, moc i liczba wybranych zmiennych: $\beta = 4$

Metoda	k = 5			k = 20			k = 100		
	FDR	Moc	Wybr.	FDR	Moc	Wybr.	FDR	Moc	Wybr.
LASSO	0.71	1.0	17	0.75	1.00	79	0.54	0.97	209
Ad. LASSO R	0.93	1.0	72	0.81	1.00	106	0.49	0.94	184
Ad. LASSO L	0.55	1.0	11	0.65	0.95	54	0.31	0.93	134
Knockoff L	0.43	0.8	7	0.19	0.85	21	0.07	0.40	43
Knockoff R	0.00	0.0	0	0.20	0.20	5	0.08	0.23	25

Table 8: FDR, moc i liczba wybranych zmiennych: $\beta = \sqrt{80/k}$

Metoda	k = 5			k = 20			k = 100		
	FDR	Moc	Wybr.	FDR	Moc	Wybr.	FDR	Moc	Wybr.
LASSO	0.82	1	28	0.71	0.75	51	0.33	0.02	3
Ad. LASSO R	0.94	1	78	0.79	0.80	76	0.73	0.08	30
Ad. LASSO L	0.78	1	23	0.59	0.65	32	0.50	0.01	2
Knockoff L	0.17	1	6	0.00	0.00	0	0.00	0.00	0
Knockoff R	0.00	0	0	0.00	0.00	0	0.00	0.00	0

Dla wariantu $\beta = 4$ metody LASSO i adaptacyjne LASSO mają wysoką moc, ale jednocześnie dość wysoki FDR. Oznacza to, że wykrywają większość zmiennych istotnych, ale wybierają też wiele zmiennych fałszywych. Knockoffy są bardziej ostrożne, dlatego mają niższy FDR, ale zwykle także niższą moc. Dla wariantu $\beta = \sqrt{80/k}$ moc metod spada wraz ze wzrostem k , ponieważ pojedyncze współczynniki są coraz mniejsze. LASSO i adaptacyjne LASSO nadal wybierają zmienne fałszywe, co daje wysoki FDR. Knockoffy mocniej ograniczają fałszywe odkrycia, ale w trudniejszych przypadkach często nie wybierają żadnych zmiennych.

2d. Powtórzenie eksperymentu 100 razy

Cały eksperyment powtórzono 100 razy. Wyniki rozdzielono na dwie tabele: pierwsza dotyczy błędu estymacji MSE, a druga własności selekcji zmiennych, czyli FDR i mocy.

Table 9: Średni MSE po 100 powtórzeniach

Wariant	Metoda	k = 5	k = 20	k = 100
$\beta = 4$	Ridge	77.14	305.83	1530.61
$\beta = 4$	LASSO	43.21	104.23	535.06
$\beta = 4$	Ad. LASSO R	70.05	106.48	591.82
$\beta = 4$	Ad. LASSO L	33.07	112.15	573.47
$\beta = \sqrt{80/k}$	Ridge	76.82	76.37	75.82
$\beta = \sqrt{80/k}$	LASSO	36.65	74.16	79.68
$\beta = \sqrt{80/k}$	Ad. LASSO R	84.18	132.61	125.87
$\beta = \sqrt{80/k}$	Ad. LASSO L	52.09	85.33	80.83

Table 10: Średni FDR i moc po 100 powtórzeniach

Wariant	Metoda	k = 5		k = 20		k = 100	
		FDR	Moc	FDR	Moc	FDR	Moc
$\beta = 4$	LASSO	0.65	0.92	0.68	0.95	0.59	0.97
$\beta = 4$	Ad. LASSO R	0.92	0.96	0.75	0.95	0.49	0.90
$\beta = 4$	Ad. LASSO L	0.48	0.88	0.56	0.95	0.42	0.90
$\beta = 4$	Knockoff L	0.00	0.00	0.23	0.84	0.17	0.54
$\beta = 4$	Knockoff R	0.00	0.00	0.16	0.55	0.23	0.28
$\beta = \sqrt{80/k}$	LASSO	0.74	0.96	0.37	0.19	0.05	0.01
$\beta = \sqrt{80/k}$	Ad. LASSO R	0.93	0.96	0.85	0.73	0.67	0.26
$\beta = \sqrt{80/k}$	Ad. LASSO L	0.58	0.92	0.34	0.12	0.00	0.00
$\beta = \sqrt{80/k}$	Knockoff L	0.21	0.60	0.08	0.03	0.00	0.00
$\beta = \sqrt{80/k}$	Knockoff R	0.24	0.36	0.14	0.02	0.00	0.00

Po 100 powtórzeniach widać, że LASSO i adaptacyjne LASSO mają zwykle niższy MSE niż ridge, szczególnie dla mniejszych wartości k . Ridge nie wykonuje selekcji zmiennych, dlatego w tabeli FDR i mocy porównano tylko metody selekcyjne. LASSO osiąga wysoką moc, ale często ma wysoki FDR, co oznacza wybór wielu fałszywych zmiennych. Knockoffy lepiej ograniczają FDR, lecz zwykle kosztem niższej mocy. Dla wariantu $\beta = \sqrt{80/k}$ i dużego k moc metod wyraźnie spada, ponieważ pojedyncze współczynniki są wtedy słabsze.

Zadanie 3

W zadaniu 3 powtórzono symulację z zadania 2 dla skorelowanych zmiennych. Przyjęto, że

$$X_i \sim N\left(0, \frac{1}{n}\Sigma\right),$$

gdzie elementy diagonalne macierzy Σ są równe 1, a pozostałe elementy są równe 0.5. Oznacza to, że zmienne objaśniające są dodatnio skorelowane.

Dla skorelowanej macierzy planu zastosowano te same metody co w zadaniu 2: ridge, LASSO, dwie wersje adaptacyjnego LASSO oraz knockoffy. Wyniki porównano za pomocą MSE, FDR oraz mocy.

Eksperyment powtórzono 100 razy. W tabeli pokazano średnie wyniki dla każdej metody i każdego wariantu β .

Table 11: Średni MSE dla skorelowanej macierzy X

Wariant	Metoda	k = 5	k = 20	k = 100
$\beta = 4$	Ridge	78.47	306.88	1315.66
$\beta = 4$	LASSO	49.68	154.58	641.25
$\beta = 4$	Ad. LASSO R	50.27	152.27	646.62
$\beta = 4$	Ad. LASSO L	55.18	198.97	831.61
$\beta = \sqrt{80/k}$	Ridge	78.51	76.38	65.46
$\beta = \sqrt{80/k}$	LASSO	54.38	85.93	148.86
$\beta = \sqrt{80/k}$	Ad. LASSO R	54.26	85.83	152.75
$\beta = \sqrt{80/k}$	Ad. LASSO L	63.57	147.58	212.35

Table 12: Średni FDR i moc dla skorelowanej macierzy X

Wariant	Metoda	k = 5		k = 20		k = 100	
		FDR	Moc	FDR	Moc	FDR	Moc
$\beta = 4$	LASSO	0.82	0.92	0.73	0.88	0.53	0.94
$\beta = 4$	Ad. LASSO R	0.72	0.80	0.69	0.88	0.50	0.94
$\beta = 4$	Ad. LASSO L	0.72	0.68	0.61	0.83	0.36	0.83
$\beta = 4$	Knockoff L	0.00	0.00	0.23	0.60	0.21	0.60
$\beta = 4$	Knockoff R	0.12	0.12	0.22	0.28	0.53	0.20
$\beta = \sqrt{80/k}$	LASSO	0.85	0.72	0.79	0.55	0.67	0.35
$\beta = \sqrt{80/k}$	Ad. LASSO R	0.78	0.64	0.73	0.54	0.65	0.33
$\beta = \sqrt{80/k}$	Ad. LASSO L	0.76	0.68	0.71	0.45	0.63	0.22
$\beta = \sqrt{80/k}$	Knockoff L	0.20	0.20	0.07	0.07	0.00	0.00
$\beta = \sqrt{80/k}$	Knockoff R	0.31	0.32	0.22	0.10	0.21	0.02

Tabele pokazują, że skorelowanie zmiennych pogarsza jakość estymacji i utrudnia selekcję zmiennych. Dla wariantu $\beta = 4$ metody LASSO nadal mają wysoką moc, ale często kosztem większego FDR. Knockoffy lepiej ograniczają fałszywe odkrycia, jednak zwykle wykrywają mniej zmiennych istotnych. Dla wariantu $\beta = \sqrt{80/k}$ moc spada wraz ze wzrostem k , ponieważ pojedyncze współczynniki są wtedy słabsze.