

Raport 1 - ADZD

Dagmara Skowron

2026-03-01

Cel sprawozdania

Celem sprawozdania jest zbadanie własności estymatora najmniejszych kwadratów w modelu regresji liniowej, gdy liczba zmiennych m jest duża w porównaniu do liczby obserwacji n .

W szczególności analizowany jest wpływ liczby zmiennych na jakość estymacji parametrów, szerokość przedziałów ufności oraz skuteczność wykrywania zmiennych istotnych, zarówno bez korekty, jak i przy zastosowaniu metod kontroli błędów wielokrotnego testowania.

Opis eksperymentu

W eksperymencie generowana jest macierz planu

$$X \in \mathbb{R}^{1000 \times 950},$$

której elementy są niezależnymi zmiennymi losowymi z rozkładu normalnego

$$X_{ij} \sim \mathcal{N}\left(0, \frac{1}{\sqrt{1000}}\right).$$

Wektor odpowiedzi konstruowany jest zgodnie z modelem

$$Y = X\beta + \varepsilon,$$

gdzie pierwsze 5 współczynników wektora β jest różnych od zera:

$$\beta = (3, 3, 3, 3, 3, 0, \dots, 0)^T,$$

a składnik losowy spełnia

$$\varepsilon \sim \mathcal{N}(0, I).$$

Analiza przeprowadzana jest dla różnych rozmiarów modelu $m \in \{5, 10, 20, 100, 500, 950\}$.

Założenia

W analizie przyjęto następujące założenia:

- obserwacje są niezależne
- zmienne objaśniające są niezależne i mają rozkład normalny
- składnik losowy ma rozkład normalny o średniej 0 i wariancji 1
- model regresji liniowej ma postać bez wyrazu wolnego

Zadanie 1

1a

W pierwszym kroku dla każdego rozważanego modelu wyznaczany jest estymator najmniejszych kwadratów

$$\hat{\beta} = (X^T X)^{-1} X^T Y,$$

a następnie przeprowadzane są testy istotności hipotez

$$H_0 : \beta_j = 0 \quad \text{przeciwko} \quad H_1 : \beta_j \neq 0.$$

Celem tej części jest ocena, które współczynniki są statystycznie istotne w zależności od liczby zmiennych w modelu.

Table 1: Wybrane wyniki estymacji MNK i testów istotności dla modelu pełnego ($m = 950$)

	Prawdziwa wartosc beta	Estymata	Bład standardowy	Statystyka t	p-wartosc
X1	3	1.538	3.833	0.401	0.690
X2	3	6.438	3.789	1.699	0.096
X3	3	1.971	4.187	0.471	0.640
X4	3	9.372	4.079	2.298	0.026
X5	3	4.505	3.319	1.358	0.181
X100	0	-14.277	3.800	-3.757	0.000
X200	0	-7.328	3.172	-2.310	0.025
X500	0	5.616	3.969	1.415	0.163
X900	0	-5.452	4.055	-1.344	0.185

Na podstawie wyników dla modelu $m = 950$ widać, że estymacja jest mało stabilna. Dla zmiennych istotnych ($X_1, \dots, X_5$) estymaty często odbiegają od wartości 3, a część z nich nie jest statystycznie istotna. Jednocześnie niektóre zmienne nieistotne ($\beta_j = 0$) uzyskują istotne p-wartości, co oznacza fałszywe odkrycia. Wynika z tego, że przy dużej liczbie zmiennych ($m \approx n$) rośnie wariancja estymatorów i trudniej poprawnie wykryć istotne zmienne.

1b

W tym podpunkcie analizowana jest zmienność estymatora β_1 . Porównywany jest bład standardowy oraz szerokość 95% przedziału ufności w zależności od liczby zmiennych m . Pozwala to ocenić wpływ wielkości modelu na dokładność estymacji.

Table 2: Porównanie precyzji estymacji parametru β_1

Liczba zmiennych (m)	Bład standardowy	Szerokość PU	Dolna granica PU	Górna granica PU
5	1.012	3.974	1.842	5.815
10	1.010	3.964	1.867	5.831
20	1.020	4.004	1.804	5.807
100	1.069	4.195	1.356	5.551
500	1.420	5.578	-0.114	5.465
950	3.833	15.399	-6.162	9.238

Z tabeli widać, jak zmienia się błąd standardowy oraz szerokość 95% przedziału ufności dla parametru β_1 w zależności od liczby zmiennych m .

Dla małych modeli wartości te są zbliżone, natomiast dla dużych modeli wyraźnie rosną - dla modelu $m = 950$ przedział jest bardzo szeroki, co oznacza dużą niepewność estymacji.

Zatem gdy m jest bliskie n , estymator $\hat{\beta}_1$ staje się mało precyzyjny.

1c

W tym podpunkcie analizowana jest liczba prawdziwych i fałszywych odkryć, czyli odpowiednio poprawnych i błędnych odrzuceń hipotezy $H_0 : \beta_j = 0$. Sprawdzany jest wpływ liczby zmiennych m na liczbę błędnych decyzji.

Table 3: Liczba prawdziwych i fałszywych odkryć bez korekty na wielokrotne testowanie

Liczba zmiennych (m)	Prawdziwe odkrycia	Fałszywe odkrycia
5	5	0
10	5	1
20	5	1
100	5	4
500	3	32
950	1	200

Widać, że wraz ze wzrostem liczby zmiennych m maleje liczba prawdziwych odkryć, a rośnie liczba fałszywych odkryć. Dla małych modeli wszystkie istotne zmienne są poprawnie wykrywane, natomiast dla dużych modeli liczba fałszywych odkryć gwałtownie rośnie. Oznacza to, że bez korekty na wielokrotne testowanie wyniki testów stają się mało wiarygodne przy dużym m .

1d

W tym podpunkcie porównywane są wyniki bez korekty oraz po zastosowaniu metod Bonferroniego i Benjamini-Hochberga. Analizowany jest ich wpływ na liczbę prawdziwych i fałszywych odkryć.

Table 4: Porównanie liczby prawdziwych i fałszywych odkryć dla różnych metod korekty

Liczba zmiennych	Bez korekty		Bonferroni		BH	
	TP	FP	TP	FP	TP	FP
5	5	0	5	0	5	0
10	5	1	5	0	5	1
20	5	1	4	0	5	1
100	5	4	2	0	3	0
500	3	32	0	0	0	0
950	1	200	0	1	0	23

Z tabeli widać, że bez korekty liczba fałszywych odkryć szybko rośnie wraz z m . Korekta Bonferroniego dobrze usuwa błędy, ale często nie wykrywa istotnych zmiennych. Metoda BH pozwala znaleźć więcej prawdziwych zależności, ale pojawia się trochę więcej błędów. Dla dużych modeli ($m = 950$) wszystkie metody mają problem z wykryciem istotnych zmiennych.

Zadanie 2

2a, 2b

W tym etapie przeprowadzono 1000 powtórzeń eksperymentu. Dla każdego modelu analizowana jest wariancja estymatora $\hat{\beta}_1$ oraz szerokość 95% przedziału ufności.

Table 5: Porównanie wariancji i szerokości przedziału ufności dla parametru $\hat{\beta}_1$

m	Wariancja		Szerokość PU	
	Sym.	Teor.	Sym.	Teor.
5	1.005	1.006	3.932	3.937
10	1.012	1.011	3.946	3.946
20	1.024	1.021	3.970	3.967
100	1.112	1.112	4.136	4.140
500	2.000	2.004	5.552	5.563
950	20.529	20.408	18.019	18.147

Tabela pokazuje, jak zmienia się wariancja estymatora $\hat{\beta}_1$ oraz szerokość 95% przedziału ufności w zależności od liczby zmiennych m .

Średnia wariancja estymatora $\hat{\beta}_1$ rośnie wraz ze wzrostem liczby zmiennych m . Podobnie rośnie szerokość przedziału ufności, co oznacza spadek precyzji estymacji. Wyniki symulacyjne są bardzo bliskie wartościom teoretycznym. Dla dużych modeli ($m = 950$) wariancja i przedziały są bardzo duże, co oznacza dużą niepewność estymacji.

2c, 2d

W tej części analizowana jest liczba prawdziwych i fałszywych odkryć oraz wartości wskaźników FWER i FDR.

Porównywane są wyniki dla testów bez korekty, korekty Bonferroni oraz metody Benjaminiego-Hochberga.

Table 6: Średnia liczba prawdziwych i fałszywych odkryć

m	Bez korekty		Bonferroni		BH	
	TP	FP	TP	FP	TP	FP
5	4.26	0.00	3.39	0.00	4.19	0.00
10	4.19	0.25	2.85	0.03	3.64	0.13
20	4.21	0.74	2.34	0.04	3.17	0.17
100	4.02	4.78	1.26	0.05	1.71	0.15
500	2.81	24.85	0.19	0.05	0.22	0.08
950	0.51	46.16	0.00	0.06	0.00	0.29

Wraz ze wzrostem liczby zmiennych m maleje liczba prawdziwych odkryć, a rośnie liczba fałszywych odkryć w przypadku testów bez korekty. Korekta Bonferroni ogranicza liczbę fałszywych odkryć, ale jednocześnie zmniejsza liczbę prawdziwych odkryć. Metoda BH też ogranicza liczbę fałszywych odkryć ale jednocześnie zachowuje więcej prawdziwych odkryć niż Bonferroni. Dla dużych modeli ($m = 950$) wszystkie metody mają bardzo niską moc, co utrudnia wykrycie rzeczywistych zależności.

Kolejna tabela przedstawia estymatory FWER i FDR. FWER oznacza prawdopodobieństwo popełnienia błędu, a FDR udział błędów wśród odkryć.

Table 7: Estymatory FWER i FDR

m	Bez korekty		Bonferroni		BH	
	FWER	FDR	FWER	FDR	FWER	FDR
5	0.000	0.000	0.000	0.000	0.000	0.000
10	0.225	0.048	0.029	0.008	0.122	0.027
20	0.529	0.131	0.040	0.014	0.149	0.038
100	0.996	0.520	0.049	0.026	0.134	0.048
500	1.000	0.894	0.049	0.043	0.064	0.047
950	1.000	0.987	0.031	0.031	0.038	0.037

Bez korekty wskaźnik FWER szybko rośnie i dla dużych modeli jest bliski 1, czyli prawie zawsze pojawia się błąd.

Korekta Bonferroniego utrzymuje FWER na niskim poziomie, ale kosztem mniejszej liczby odkryć.

Metoda BH ogranicza liczbę błędów, ale nadal pozwala wykryć więcej istotnych zmiennych.

2e

W ostatnim etapie porównywane są wyniki symulacyjne z odpowiednimi wartościami teoretycznymi. Analiza dotyczy liczby fałszywych i prawdziwych odkryć oraz poziomu błędu FWER.

Table 8: Porównanie wyników symulacyjnych z oszacowaniami teoretycznymi

m	Bez korekty				Bonferroni			
	FP sym.	FP teor.	FWER sym.	FWER teor.	FP sym.	FP teor.	FWER sym.	FWER teor.
5	0.000	0.00	0.000	0.000	0.000	0.000	0.000	0.05
10	0.251	0.25	0.225	0.226	0.032	0.025	0.029	0.05
20	0.736	0.75	0.529	0.537	0.040	0.038	0.040	0.05
100	4.782	4.75	0.996	0.992	0.050	0.048	0.049	0.05
500	24.847	24.75	1.000	1.000	0.052	0.050	0.049	0.05
950	46.160	47.25	1.000	1.000	0.057	0.050	0.031	0.05

Wyniki symulacyjne są dość zbliżone do wartości teoretycznych, zarówno dla liczby fałszywych odkryć, jak i dla FWER. Dla testów bez korekty liczba fałszywych odkryć rośnie wraz z m zgodnie z przewidywaniami teoretycznymi, a FWER szybko osiąga wartość bliską 1. Korekta Bonferroniego dobrze kontroluje FWER na poziomie α . Dla korekty Bonferroniego FWER teoretycznie wynosi $\alpha = 0.05$, ponieważ metoda ta z założenia kontroluje poziom błędu.

Teoretyczna liczba prawdziwych odkryć jest stała i wynosi 5, ponieważ tylko pierwsze 5 parametrów w wektorze β jest niezerowych. W praktyce liczba wykrytych istotnych zmiennych może być jednak mniejsza, ponieważ zależy od mocy testu.