

Raport 2

Dagmara Skowron

2026-03-22

Cel sprawozdania

Celem sprawozdania jest porównanie różnych metod estymacji parametrów w modelu regresji liniowej przy dużej liczbie zmiennych.

Porównano estymator najmniejszych kwadratów oraz estymatory Jamesa-Steina. Sprawdzono również, jak działają procedury wielokrotnego testowania hipotez: Bonferroniego, Benjaminiego-Hochberga oraz klasyfikator Bayesowski.

Jako kryterium porównania wykorzystano błąd średniokwadratowy oraz liczbę błędów pierwszego i drugiego rodzaju.

Opis eksperymentu

Wygenerowano macierz planu $X \in \mathbb{R}^{1000 \times 1000}$, która jest ortonormalna, tzn. spełnia warunek $X^T X = I$.

Następnie wygenerowano wektor parametrów β . Większość jego współrzędnych jest równa 0, a tylko część pochodzi z rozkładu normalnego $N(0, \tau^2)$.

Rozważono różne wartości parametrów:

$$\gamma \in \{0.01, 0.05, 0.1\}, \quad \tau \in \{1.5\sqrt{2 \log 1000}, 3\sqrt{2 \log 1000}\}.$$

Na tej podstawie wygenerowano wektor odpowiedzi:

$$Y = X\beta + \varepsilon,$$

gdzie $\varepsilon \sim N(0, I)$ oraz $\sigma^2 = 1$.

Dla każdej kombinacji parametrów przeprowadzono analizę i powtórzono eksperyment wiele razy.

Założenia

W analizie przyjęto, że:

- model ma postać $Y = X\beta + \varepsilon$
- macierz X jest ortonormalna
- $\varepsilon \sim N(0, I)$
- wariancja błędu wynosi $\sigma^2 = 1$
- większość współczynników β jest równa 0
- obserwacje są niezależne

W klasyfikatorze Bayesowskim przyjęto taki sam koszt błędów pierwszego i drugiego rodzaju.

Zadanie 1

a) Estymator najmniejszych kwadratów i jego rozkład

Estymator najmniejszych kwadratów ma postać:

$$\hat{\beta}^{LS} = (X^\top X)^{-1} X^\top Y.$$

Ponieważ macierz X jest ortonormalna ($X^\top X = I$), otrzymuje się:

$$\hat{\beta}^{LS} = X^\top Y.$$

Rozkład estymatora MNK

Estymator ma rozkład:

$$\hat{\beta}^{LS} \sim N(\beta, \sigma^2(X^\top X)^{-1}).$$

W rozważanym przypadku:

$$\hat{\beta}^{LS} \sim N(\beta, I).$$

b) Estymatory Jamesa-Steina

Estymatory Jamesa-Steina polegają na „ściągnięciu” estymatora MNK w celu zmniejszenia błędu średniokwadratowego.

Estymator ściągający do zera

$$\hat{\beta}^{JS} = \left(1 - \frac{p-2}{\|\hat{\beta}^{LS}\|^2}\right) \hat{\beta}^{LS}.$$

Estymator ściągający do wspólnej średniej

Niech

$$\bar{\beta}^{LS} = \frac{1}{p} \sum_{i=1}^p \hat{\beta}_i^{LS}.$$

Wówczas:

$$\hat{\beta}^{JS, mean} = \bar{\beta}^{LS} + \left(1 - \frac{p-3}{\|\hat{\beta}^{LS} - \bar{\beta}^{LS} \mathbf{1}\|^2}\right) (\hat{\beta}^{LS} - \bar{\beta}^{LS} \mathbf{1}).$$

Dla $p \geq 3$ estymatory Jamesa-Steina mają mniejszy MSE niż MNK.

Zadanie 2

Celem jest wyznaczenie istotnych współczynników. Testowane są hipotezy:

$$H_{0i} : \beta_i = 0 \quad \text{vs} \quad H_{1i} : \beta_i \neq 0.$$

Ponieważ $\hat{\beta}^{LS} \sim N(\beta, I)$, statystyka testowa ma postać:

$$T_i = \hat{\beta}_i^{LS}.$$

P -wartości obliczono ze wzoru:

$$p_i = 2(1 - \Phi(|T_i|)).$$

a) Procedura Bonferroniego

Hipotezę H_{0i} odrzuca się, gdy:

$$p_i \leq \frac{\alpha}{p}.$$

Procedura ta jest ostrożna — dobrze kontroluje błędy pierwszego rodzaju, ale może mieć małą moc.

b) Procedura Benjaminiego-Hochberga

P -wartości porządkuje się rosnąco:

$$p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(p)}.$$

Następnie wyznacza się:

$$k = \max \left\{ i : p_{(i)} \leq \frac{i}{p} \alpha \right\}.$$

Odrzuca się hipotezy odpowiadające $p_{(1)}, \dots, p_{(k)}$.

c) Klasyfikator Bayesowski

Zakłada się model:

$$\beta_i \sim (1 - \gamma)\delta_0 + \gamma N(0, \tau^2).$$

Rozważane są hipotezy:

$$H_{0i} : \beta_i = 0, \quad H_{1i} : \beta_i \sim N(0, \tau^2).$$

Decyzję podejmuje się na podstawie obserwacji $\hat{\beta}_i^{LS}$. Pod hipotezą zerową:

$$\hat{\beta}_i^{LS} \sim N(0, 1),$$

natomiast pod hipotezą alternatywną:

$$\hat{\beta}_i^{LS} \sim N(0, 1 + \tau^2).$$

Odrzuca się hipotezę zerową, gdy:

$$\gamma f_1(\hat{\beta}_i^{LS}) > (1 - \gamma) f_0(\hat{\beta}_i^{LS}),$$

gdzie f_0 i f_1 oznaczają odpowiednie gęstości rozkładów normalnych.

Przyjęto jednakowy koszt błędów pierwszego i drugiego rodzaju.

Porównanie procedur

W celu porównania procedur testowania wyznaczono liczbę zmiennych uznanych za istotne przez każdą z metod. Wyniki przedstawiono w tabeli poniżej.

Table 1: Liczba zmiennych uznanych za istotne

metoda	liczba istotnych zmiennych
Bonferroni	19
BH	26
Bayes	28

Tabela pokazuje, że procedura Bonferroniego wykrywa najmniej zmiennych, natomiast metoda Benjaminiego-Hochberga oraz klasyfikator Bayesowski wskazują większą liczbę istotnych współczynników, co wynika z ich mniej ostrożnego charakteru.

Zadanie 3

Dla każdej procedury z zadania 2 skonstruowano estymatory ucięte wektora β .

Estymator ucięty ma postać:

$$\hat{\beta}_i^{uc} = \begin{cases} \hat{\beta}_i^{LS}, & \text{jeżeli odrzucono } H_{0i}, \\ 0, & \text{w przeciwnym przypadku.} \end{cases}$$

Oznacza to, że pozostawiono tylko te współczynniki, które uznano za istotne, a pozostałe przyjęto równe zero.

W ten sposób otrzymano trzy estymatory ucięte odpowiadające procedurze Bonferroniego, Benjaminiego-Hochberga oraz klasyfikatorowi Bayesowskiemu.

Table 2: Liczba niezerowych współczynników w estymatorach uciętych

estymator	liczba niezerowych współczynników
Ucięty Bonferroni	19
Ucięty BH	26
Ucięty Bayes	28

Z tabeli widać, że liczba niezerowych współczynników w estymatorach uciętych jest taka sama jak liczba zmiennych uznanych za istotne w zadaniu 2, co wynika bezpośrednio z konstrukcji estymatora uciętego. Oznacza to, że każda z procedur selekcji zmiennych bezpośrednio wpływa na liczbę niezerowych współczynników w estymatorze.

Zadanie 4

W tym zadaniu porównano otrzymane estymatory oraz procedury testowania.

Oceny dokonano na podstawie błędu kwadratowego estymacji oraz liczby błędów pierwszego i drugiego rodzaju. Analizę przeprowadzono dla różnych wartości parametrów oraz na podstawie wielokrotnych powtórzeń eksperymentu.

a)

W pierwszej części porównano estymatory z zadania 1 i 3 pod względem błędu kwadratowego:

$$SE = \|\hat{\beta} - \beta\|^2.$$

Dla każdego estymatora obliczono wartość błędu. Wyniki przedstawiono w tabelach 3 i 4.

Table 3: Porównanie estymatorów pod względem MSE dla $\tau = 1.5\sqrt{2\log 1000}$

estymator	gamma = 0.01	gamma = 0.05	gamma = 0.1
JS do średniej	112.607	294.847	376.304
JS do zera	111.713	294.334	376.024
MNK	500.440	496.132	495.491
Ucięty BH	15.474	65.162	113.418
Ucięty Bayes	15.981	65.140	112.488
Ucięty Bonferroni	17.645	81.881	155.554

Table 4: Porównanie estymatorów pod względem MSE dla $\tau = 3\sqrt{2\log 1000}$

estymator	gamma = 0.01	gamma = 0.05	gamma = 0.1
JS do średniej	210.882	429.667	458.202
JS do zera	210.530	429.502	458.132
MNK	495.507	502.498	501.978
Ucięty BH	12.367	51.864	91.576
Ucięty Bayes	11.460	50.935	89.689
Ucięty Bonferroni	11.476	62.022	108.355

Na podstawie tabeli 3 oraz tabeli 4 widać, że estymator najmniejszych kwadratów osiąga największe wartości błędu, co potwierdza jego słabe działanie w przypadku dużej liczby zmiennych.

Estymatory Jamesa-Steina poprawiają wyniki względem MNK, jednak nadal są gorsze od estymatorów uciętych.

Najmniejsze wartości MSE uzyskano dla estymatorów uciętych, szczególnie dla metody Benjaminiego-Hochberga oraz klasyfikatora Bayesowskiego.

Procedura Bonferroniego daje gorsze wyniki od pozostałych metod uciętych, poprzez jej bardziej ostrożny charakter.

Dodatkowo w obu tabelach widać, że wraz ze wzrostem wartości γ rośnie błąd estymacji, co wynika z większej liczby niezerowych współczynników.

b) i c)

W tej części porównano procedury testowania pod względem sumy liczby błędów pierwszego i drugiego rodzaju.

Dla każdej procedury obliczono średnią wartość tej sumy. Wyniki przedstawiono w tabelach 5 i 6.

Table 5: Porównanie procedur pod względem średniej sumy błędów dla $\tau = 1.5\sqrt{2\log 1000}$

procedura	gamma = 0.01	gamma = 0.05	gamma = 0.1
BH	2.34	11.44	21.12
Bayes	2.38	11.38	20.94
Bonferroni	2.50	12.74	25.06

Table 6: Porównanie procedur pod względem średniej sumy błędów dla $\tau = 3\sqrt{2\log 1000}$

procedura	gamma = 0.01	gamma = 0.05	gamma = 0.1
BH	1.54	6.00	11.38
Bayes	1.48	5.98	11.26
Bonferroni	1.46	6.78	13.16

Na podstawie tabeli 5 oraz tabeli 6 widać, że procedura Bonferroniego osiąga największą średnią sumę błędów. Procedura Benjaminiego-Hochberga oraz klasyfikator Bayesowski dają lepsze wyniki i mają zbliżoną skuteczność. Dodatkowo w obu tabelach można zauważyć, że wraz ze wzrostem wartości γ rośnie liczba popełnianych błędów. Dla większych wartości parametru τ suma błędów jest mniejsza, co wynika z bardziej wyraźnych zależności w danych.