

Raport 3

Dagmara Skowron

2026-04-28

Cel sprawozdania

Celem sprawozdania jest analiza wpływu liczby zmiennych na błąd predykcji.

Porównujemy także kryteria AIC, BIC, RIC, mBIC oraz mBIC2 pod względem skuteczności wyboru istotnych zmiennych.

Opis eksperymentu

Dane generowane są z modelu liniowego

$$Y = X\beta + \varepsilon.$$

W pierwszej części analizujemy modele zbudowane z pierwszych: 10, 20, 30, 50, 100, 500 oraz 950 predyktorów. Dla każdego modelu obliczamy RSS, rzeczywisty błąd predykcji oraz jego estymatory. Następnie sprawdzamy, który model jest wybierany jako optymalny.

W drugiej części stosujemy kryteria AIC, BIC, RIC, mBIC oraz mBIC2 do selekcji zmiennych. Jakość wyboru oceniamy za pomocą liczby prawdziwych i fałszywych odkryć, mocy, FDR oraz błędu estymacji $EY = X\beta$.

Cały eksperyment wykonujemy dla $n = 1000$, $p = 950$, a następnie powtarzamy analizę dla $n = 5000$. Wyniki symulacyjne opierają się na 100 powtórzeniach.

Założenia

W analizie przyjmujemy:

$$X_{ij} \sim \mathcal{N}\left(0, \frac{1}{n}\right),$$

$$\beta_1 = \dots = \beta_{20} = 3.5,$$

$$\beta_i = 0 \quad \text{dla } i > 20,$$

$$\varepsilon \sim \mathcal{N}(0, I).$$

Zakładamy, że elementy macierzy X są niezależne oraz że składnik losowy ε jest niezależny od X . Modele liniowe estymujemy metodą najmniejszych kwadratów.

Zadanie 1a

W tej części analizujemy jakość predykcji modeli liniowych o różnej liczbie predyktorów. Celem jest porównanie rzeczywistego błędu predykcji z jego estymatorami oraz ocena ich dokładności.

Dla wygenerowanych danych dopasowujemy modele wykorzystujące rosnącą liczbę zmiennych objaśniających. Dla każdego modelu obliczamy RSS oraz rzeczywisty błąd predykcji:

$$PE = \mathbb{E}\|Y^* - \hat{Y}\|^2,$$

gdzie $Y^* = X\beta + \varepsilon^*$, a ε^* jest niezależnym wektorem losowym.

Następnie wyznaczamy estymatory błędu predykcji oparte na RSS oraz metodzie walidacji krzyżowej typu leave-one-out (LOOCV).

Table 1: Porównanie błędu predykcji oraz jego estymatorów

liczba_zmiennych	RSS	PE	PE_RSS_sigma_znane	PE_RSS_sigma_est	PE_LOOCV
10	1082.59	1131.49	1102.59	1104.46	1104.44
20	975.37	1021.14	1015.37	1015.18	1014.99
30	957.71	1038.81	1017.71	1016.95	1017.32
50	932.66	1063.85	1032.66	1030.84	1031.72
100	901.20	1095.32	1101.20	1101.46	1111.27
500	497.35	1499.17	1497.35	1492.04	1999.63
950	36.07	1960.44	1936.07	1406.86	15527.14

Wnioski

Na podstawie tabeli widać, że RSS maleje wraz ze wzrostem liczby zmiennych, ponieważ model coraz lepiej dopasowuje dane treningowe. Rzeczywisty błąd predykcji jest najmniejszy dla modelu z 20 predyktorami. Jest to zgodne z konstrukcją danych, ponieważ dokładnie 20 zmiennych ma niezerowe współczynniki. Dla większych modeli PE rośnie. Estymatory oparte na RSS dobrze wskazują model optymalny, natomiast LOOCV staje się niestabilny dla bardzo dużej liczby zmiennych.

Zadanie 1b

Na podstawie uzyskanych estymatorów błędu predykcji wybieramy optymalny model, czyli model minimalizujący daną miarę błędu. Porównanie pozwala sprawdzić, czy różne estymatory prowadzą do tego samego wyboru liczby zmiennych.

Table 2: Wybór optymalnego modelu według różnych kryteriów

Kryterium	Optymalna liczba zmiennych	Minimalna wartość
Rzeczywisty PE	20	1021.14
RSS + 2k, sigma znane	20	1015.37
RSS + 2k, sigma estymowane	20	1015.18
LOOCV	20	1014.99

Wnioski

Tabela pokazuje, że wszystkie metody wskazały model z 20 zmiennymi jako najlepszy. Jest to zgodne z założeniami zadania, ponieważ dokładnie 20 zmiennych ma niezerowe współczynniki. Oznacza to, że zastosowane estymatory błędu predykcji poprawnie wybrały właściwy model. Mimo że metody liczą błąd w różny sposób to dały ten sam wynik.

Zadanie 1c


W celu oceny stabilności estymatorów eksperyment powtarzamy 100 razy. Dla każdego modelu porównujemy różnice między estymowanym a rzeczywistym błędem predykcji.

Table 3: Podsumowanie błędów estymacji PE

liczba_zmiennych	metoda	Średni błąd	Mediana błędu	Odchylenie standardowe
10	LOOCV	8.70	8.37	54.65
	RSS, sigma estymowane	8.57	8.24	54.56
	RSS, sigma znane	6.01	5.66	53.49
20	LOOCV	4.88	-2.13	51.37
	RSS, sigma estymowane	4.40	-2.39	51.22
	RSS, sigma znane	4.25	-2.33	49.21
30	LOOCV	4.81	5.31	50.52
	RSS, sigma estymowane	3.76	4.61	50.36
	RSS, sigma znane	3.56	4.71	47.39
50	LOOCV	7.58	9.84	52.96
	RSS, sigma estymowane	4.71	6.85	52.77
	RSS, sigma znane	4.32	6.28	47.77
100	LOOCV	19.23	17.65	58.87
	RSS, sigma estymowane	7.82	5.92	58.18
	RSS, sigma znane	6.73	6.22	47.92
500	LOOCV	506.92	502.58	125.45
	RSS, sigma estymowane	1.71	1.68	95.36
	RSS, sigma znane	-0.68	-1.38	41.01
950	LOOCV	18093.91	17809.85	3473.07
	RSS, sigma estymowane	-76.48	-120.97	334.32
	RSS, sigma znane	-6.74	-3.38	51.97

Na podstawie tabeli widać, że dla małej i średniej liczby zmiennych wszystkie estymatory mają średni błąd bliski zeru. Oznacza to, że dobrze przybliżają rzeczywisty błąd predykcji. Dla większych modeli różnice między metodami są bardziej widoczne. Szczególnie dla modelu z 950 zmiennymi metoda LOOCV daje bardzo duży błąd, co wskazuje na jej niestabilność.

Poniższy wykres przedstawia rozkład błędów estymacji $\widehat{PE} - PE$ dla trzech estymatorów błędu predykcji. Porównujemy modele z liczbą zmiennych od 10 do 500. Model z 950 zmiennymi pominięto na wykresie, ponieważ bardzo duże wartości błędu dla LOOCV zaburzały skalę.



Na podstawie wykresu widać, że estymatory oparte na RSS są dość stabilne. Ich wartości są skupione blisko zera dla większości modeli. Metoda LOOCV działa podobnie dla małej liczby zmiennych, ale dla modelu z 500 zmiennymi wyraźnie zawyża błąd. Oznacza to, że LOOCV traci stabilność przy dużej liczbie predyktorów.

Zadanie 2

Celem zadania jest porównanie kryteriów AIC, BIC, RIC, mBIC i mBIC2 w kontekście wyboru zmiennych w modelu liniowym oraz ocena ich skuteczności przy różnych liczbach predyktorów.

Ze względu na duży koszt obliczeniowy procedury selekcji zmiennych analizę w zadaniu 2 ograniczamy do modeli z liczbą predyktorów $p \leq 500$. Dla $p = 950$ czas obliczeń był bardzo długi. Wnioski interpretujemy więc dla zakresu $p = 50, 100, 200, 500$.

a) Na początku analizujemy wyniki dla pojedynczej symulacji. Dla każdego rozważanego rozmiaru zbioru predyktorów oraz dla każdego kryterium (AIC, BIC, RIC, mBIC, mBIC2) wyznaczamy zbiór wybranych zmiennych, a następnie obliczamy liczbę prawdziwych i fałszywych odkryć oraz błąd estymacji wektora $E(Y) = X\beta$.

Table 4: Wyniki wyboru zmiennych

p	Kryterium	Prawdziwe odkrycia	Fałszywe odkrycia	SE
50	AIC	20	10	53.23
50	BIC	16	0	65.25
50	RIC	16	0	65.25
50	mBIC	11	0	119.77
50	mBIC2	18	0	42.28
100	AIC	20	13	62.82
100	BIC	16	0	65.25
100	RIC	14	0	86.10
100	mBIC	8	0	160.89
100	mBIC2	16	0	65.25
200	AIC	20	33	142.04

200	BIC	17	4	87.01
200	RIC	12	1	119.43
200	mBIC	8	0	160.89
200	mBIC2	15	1	87.99
500	AIC	19	111	347.76
500	BIC	17	4	87.01
500	RIC	9	0	145.36
500	mBIC	7	0	171.34
500	mBIC2	9	1	155.53

Wnioski

Wyniki w tabeli dla pojedynczej symulacji pokazują wyraźne różnice między kryteriami wyboru zmiennych. Kryterium AIC wybiera największą liczbę zmiennych i osiąga najwyższą liczbę prawdziwych odkryć, jednak kosztem obecności wielu fałszywych zmiennych. Z kolei BIC, RIC oraz mBIC wybierają mniej zmiennych, ale praktycznie eliminują fałszywe odkrycia. Kryterium mBIC2 pozwala odzyskać większą liczbę istotnych zmiennych niż mBIC, jednocześnie nie wprowadzając błędnych predyktorów.

b) W tym podpunkcie powtarzamy procedurę selekcji zmiennych 100 razy. Dla każdego kryterium obliczamy średnią liczbę wybranych zmiennych, średnią liczbę prawdziwych i fałszywych odkryć, moc, FDR oraz średni błąd SE. Dzięki temu możemy ocenić, które kryteria są stabilne i jak zmienia się ich skuteczność przy rosnącej liczbie predyktorów.

Table 5: Podsumowanie wyników po 100 powtórzeniach

p	Kryterium	Śr. TP	Śr. FP	Moc	FDR	Śr. SE
50	AIC	19.55	4.85	0.98	0.20	42.44
50	BIC	15.85	0.40	0.79	0.02	64.09
50	RIC	14.70	0.15	0.74	0.01	74.81
50	mBIC	9.25	0.00	0.46	0.00	133.70
50	mBIC2	16.55	0.75	0.83	0.04	58.44
100	AIC	19.60	13.90	0.98	0.41	75.50
100	BIC	15.80	1.05	0.79	0.06	70.80
100	RIC	13.55	0.40	0.68	0.03	90.34
100	mBIC	7.65	0.05	0.38	0.00	151.81
100	mBIC2	14.65	0.45	0.73	0.03	78.95
200	AIC	19.55	31.45	0.98	0.61	130.04
200	BIC	15.75	1.35	0.79	0.08	73.31
200	RIC	11.40	0.25	0.57	0.02	112.31
200	mBIC	5.90	0.00	0.30	0.00	170.97
200	mBIC2	12.45	0.50	0.62	0.03	102.75
500	AIC	19.30	110.40	0.96	0.85	355.30
500	BIC	15.40	4.90	0.77	0.23	104.37
500	RIC	8.20	0.35	0.41	0.04	149.35
500	mBIC	4.20	0.00	0.21	0.00	192.23
500	mBIC2	8.50	0.35	0.42	0.04	145.26

Wnioski

Średnie wyniki potwierdzają obserwacje z pojedynczej symulacji. Kryterium AIC charakteryzuje się najwyższą mocą, jednak prowadzi do dużej liczby fałszywych odkryć. Kryteria BIC i RIC są bardziej ostrożne — wybierają mniej zmiennych, dlatego mają niższą moc, ale lepiej kontrolują FDR.

Kryterium mBIC jest najbardziej restrykcyjne, co skutkuje bardzo małą liczbą fałszywych odkryć, ale także niską mocą. Natomiast mBIC2 zapewnia stosunkowo wysoką moc przy jednoczesnym zachowaniu niskiego poziomu FDR.

Zadanie 3

W tym zadaniu powtarzamy analizy z poprzednich zadań dla większej liczby obserwacji ($n = 5000$), aby ocenić wpływ wielkości próby na jakość estymacji oraz skuteczność metod wyboru zmiennych.

a) Obliczenie PE i jego estymatorów

W pierwszej części analizujemy błąd predykcji dla $n = 5000$. Porównujemy rzeczywisty błąd PE z jego estymatorami dla modeli o różnej liczbie zmiennych.

Table 6: Wartości PE i jego estymatorów dla $n = 5000$

liczba_zmiennych	RSS	PE	PE_RSS_sigma_znane	PE_RSS_sigma_est	PE_LOOCV
10	5013.19	5126.18	5035.19	5035.29	5035.13
20	4874.60	5013.57	4916.60	4915.72	4915.55
30	4863.07	5025.10	4925.07	4923.75	4923.37
50	4840.71	5047.45	4942.71	4940.48	4940.58
100	4797.34	5090.83	4999.34	4995.14	4996.63
500	4441.67	5446.50	5443.67	5430.90	5482.27
950	3995.04	5893.13	5897.04	5871.69	6089.96

Wnioski:

Na podstawie tabeli widać, że wszystkie estymatory błędu predykcji osiągają minimum dla modeli o liczbie zmiennych około 20–30, czyli bliskiej rzeczywistej liczbie istotnych predyktorów. Oznacza to, że dobrze przybliżają prawdziwy błąd predykcji. Dla większych modeli wartość PE rośnie, co oznacza, że model staje się zbyt złożony i gorzej przewiduje nowe dane.

b) Wybór optymalnego modelu

W tym podpunkcie wybieramy najlepszy model dla $n = 5000$. Za najlepszy uznajemy ten model, dla którego dana miara błędu predykcji przyjmuje najmniejszą wartość.

Table 7: Wybór optymalnego modelu dla $n = 5000$


Kryterium	Optymalna liczba zmiennych	Minimalna wartość
Rzeczywisty PE	20	5013.57
RSS + 2k, sigma znane	20	4916.60
RSS + 2k, sigma estymowane	20	4915.72
LOOCV	20	4915.55

Wnioski

Na podstawie tabeli widać, że wszystkie kryteria wskazują ten sam optymalny model, zawierający 20 zmiennych, co odpowiada rzeczywistej liczbie istotnych predyktorów. Oznacza to, że estymatory błędu predykcji bardzo dobrze identyfikują właściwy model. Dodatkowo wartości kryteriów są do siebie zbliżone, co potwierdza ich wysoką dokładność dla większej liczby obserwacji.

Wykres różnic błędów predykcji

Poniższy wykres pokazuje różnice między estymowanym a rzeczywistym błędem predykcji dla $n = 5000$. Porównujemy trzy estymatory błędu predykcji dla różnych liczby zmiennych w modelu.



Wykres pokazuje, że dla mniejszych modeli wszystkie estymatory dają wyniki dość bliskie rzeczywistemu błędowi predykcji. Różnice są skupione w pobliżu zera. Dla większej liczby zmiennych, szczególnie dla 500 i 950 predyktorów, metoda LOOCV staje się mniej stabilna i częściej zawyża błąd. Estymatory oparte na RSS pozostają bardziej stabilne. Wyniki potwierdzają, że przy większej liczbie obserwacji estymacja błędu predykcji jest dokładniejsza, ale bardzo duża liczba predyktorów nadal może pogarszać stabilność metod.

Zadanie 3.2 — selekcja zmiennych dla $n = 5000$

W tej części powtarzamy selekcję zmiennych dla większej liczby obserwacji, czyli dla $n = 5000$. Dla różnych liczby predyktorów porównujemy kryteria AIC, BIC, RIC, mBIC oraz mBIC2. Sprawdzamy, ile zmiennych zostało wybranych, ile z nich było prawdziwie istotnych oraz ile było fałszywych odkryć.

Table 8: Wyniki selekcji zmiennych dla jednej symulacji, $n = 5000$

Liczba predyktorów	Kryterium	TP	FP	SE
50	AIC	20	7	38.81
50	BIC	12	0	103.65
50	RIC	12	0	103.65
50	mBIC	6	0	175.90
50	mBIC2	12	0	103.65
100	AIC	20	14	69.17
100	BIC	12	1	112.76
100	RIC	12	1	112.76
100	mBIC	5	0	186.25
100	mBIC2	11	0	115.59
200	AIC	20	25	126.30
200	BIC	12	2	122.97
200	RIC	9	0	140.63
200	mBIC	5	0	186.25
200	mBIC2	7	0	162.91

500	AIC	20	76	302.41
500	BIC	12	3	133.29
500	RIC	7	0	162.91
500	mBIC	2	0	221.72
500	mBIC2	5	0	186.25
950	AIC	20	161	613.62
950	BIC	12	6	165.99
950	RIC	6	0	175.90
950	mBIC	2	0	221.72
950	mBIC2	2	0	221.72

Wnioski

W pojedynczej symulacji kryterium AIC wybiera najwięcej zmiennych. Dzięki temu odzyskuje wszystkie istotne predyktory, ale jednocześnie wprowadza dużo fałszywych odkryć, szczególnie dla dużej liczby predyktorów. Kryteria BIC, RIC, mBIC i mBIC2 są bardziej ostrożne. Wybierają mniej zmiennych i mają mniej fałszywych odkryć, ale często pomijają część prawdziwie istotnych predyktorów. Najbardziej restrykcyjne jest mBIC. Nie wybiera fałszywych zmiennych, ale ma też najmniejszą liczbę prawdziwych odkryć.

Powtórzenie selekcji zmiennych

W tej części selekcję zmiennych powtarzamy 100 razy dla $n = 5000$. Dla każdego kryterium obliczamy średnią moc, FDR oraz średni błąd estymacji SE .

Table 9: Skuteczność kryteriów selekcji zmiennych dla $n = 5000$

liczba_predyktorow	kryterium	Moc	FDR	Średni SE
50	AIC	0.96	0.237	55.50
50	BIC	0.66	0.034	99.40
50	RIC	0.67	0.044	98.26
50	mBIC	0.46	0.000	143.26
50	mBIC2	0.65	0.048	102.89
100	AIC	0.95	0.409	79.21
100	BIC	0.66	0.034	99.40
100	RIC	0.61	0.022	109.06
100	mBIC	0.40	0.000	157.35
100	mBIC2	0.59	0.025	113.81
200	AIC	0.96	0.600	134.88
200	BIC	0.66	0.047	101.31
200	RIC	0.59	0.025	113.81
200	mBIC	0.30	0.000	182.13
200	mBIC2	0.55	0.000	121.00
500	AIC	0.96	0.813	324.19
500	BIC	0.66	0.088	107.12
500	RIC	0.48	0.000	137.91
500	mBIC	0.22	0.000	200.07
500	mBIC2	0.46	0.000	143.26
950	AIC	0.96	0.899	623.20
950	BIC	0.65	0.202	130.59
950	RIC	0.45	0.033	148.85
950	mBIC	0.21	0.000	202.27
950	mBIC2	0.36	0.000	167.33

Wnioski

Na podstawie tabeli widać, że AIC ma najwyższą moc, ale jednocześnie najwyższy FDR. Oznacza to, że często wykrywa zmienne istotne, ale wybiera też wiele fałszywych odkryć.

mBIC najlepiej ogranicza fałszywe odkrycia, ale ma najniższą moc. BIC, RIC i mBIC2 dają wyniki pośrednie. mBIC2 wykrywa więcej istotnych zmiennych niż mBIC, ale nadal dobrze ogranicza liczbę fałszywych odkryć.

Wraz ze wzrostem liczby predyktorów FDR dla AIC wyraźnie rośnie, co pokazuje, że selekcja staje się trudniejsza.